曾祥哲

AI Agent 平台研发工程师（Memory ·RAG ·Skill ·Agent 运行时）

xz@xzos.net | +86 15530859511 | github.com/xz-dev | xzos.net

个人简介

4 年后端/全栈经验，现在 Capital Dynamics 负责公司 AI Agent 基础设施：设计并落地 Memory/RAG/Skill 体系与模型网关，并把能力以服务形式开放给业务；此前在 Klavis AI 主导 MCP 工具平台（Strata 引擎，能力注册与编排）。日常以 Vibe Coding 重度使用编码 Agent，维护 Pi 下游分支及 Memory/续接/重试插件，对 Hermes Agent、Claude Code 类系统的 Agent Loop、Memory 与 Skill 有源码级实践，并向上游持续贡献（见开源成就）。
工程方法：先建基线再迁移（旧系统先容器化＋回归测试再重构）；**结果不确定时不假设成功**（工具调用无返回标为"效果未知"，不自动重跑）；**边界与权限显式化**（按用户过滤模型、会话标识只路由不鉴权、网络只放行必要目标）；**修在根因并回馈上游**（问题先在自己系统复现，再提交到上游）。

开源成就

- Agent Memory：pi-hermes-memory（Pi 的 Hermes 式记忆插件）合并 7 个 PR，含原子化应用记忆合并计划；Honcho（7.9k Stars，Agent 记忆框架）合并 deriver 启动健康检查修复。
- Agent 运行时/子 Agent：pi-subagents（4.1k Stars）合并 7 个 PR，涵盖异步完成结果持久取回、分支子会话隔离、MCP 请求头缓存；Pi 编码 Agent（119k Stars）合并 #6764、#6697。
- MCP/Skill 工具平台：Klavis-AI/klavis（5.8k Stars）合并 34 个 PR，Strata 引擎与 20+ 第三方 MCP 集成（能力注册、检索与编排）。
- 模型网关：OmniRoute（84k Stars）提交 57 个 PR、合并 50 个，覆盖过载控制、模型权限、配额回退、推理流；APISIX AISIX 合并 2 个代理性能 PR；Sub2API（45k Stars）合并 2 个模型清单 PR。
- Agent 前端：Hermes WebUI（19k Stars）合并 2 个 PR（会话用量计量、推理卡片状态）。
- 运行时基础：Deno（108k Stars）子进程信号修复、youki（Rust OCI 运行时）均已合并；virtio-win 合并 4 个 PR（含 RHEL-149886）；ansible-runner #1306。
- 自有项目：UpgradeAll 发起人（1.3k+ Stars）；AI-gateway 31 Stars；Pi 下游分支 16 Stars。
- 总计：2018 年起向他人仓库合并 PR 368 个（GitHub 搜索，2026-11），GitHub 200+ 公开仓库。

专业技能

Agent 与 LLM：Agent Loop/工具调用、Context Engineering（上下文压缩与续接）、Agent Memory（存储/检索/管理/演化：mem0、Honcho、Hindsight、Hermes 风格记忆）、RAG 检索与上下文构建（召回＋语义重排）、Skill/插件注册与编排、子 Agent、MCP；Hermes Agent/Pi/Claude Code 重度使用（Vibe Coding）。
网关与协议：APISIX（Lua）、OpenAI/Anthropic 兼容 API、SSE、WebSocket、gRPC、REST、OAuth 2.0、SSO/MFA。
语言与数据：Python（Django/DRF、FastAPI、asyncio）、Go、TypeScript/Node.js/Bun、Rust、C#/.NET、Java/Spring Boot、C/C++；PostgreSQL、Redis/Celery、SQLite。
部署与运维：Docker/Podman、Kubernetes、Helm、KEDA、Ansible、GitHub Actions、Azure、GCP、Linux；OpenTelemetry/Jaeger/Loki/Grafana。

工作经历

Capital Dynamics（上海） | AI 与全栈开发工程师 2026.05 – 至今

负责公司 AI Agent 基础设施与应用，牵头香港投资人门户重构；约 4 个月提交 1388 commits、122 个 MR（105 合并）。

- Agent Memory 与 RAG：搭建 LLM Wiki 与基于 mem0 的共享记忆库，设计双记忆架构覆盖记忆的存储、检索、管理与演化（Honcho 管长期画像与偏好、Hindsight 管实体/事件关系图谱，补全省略指代）；为全体员工部署 Thunderbird 邮件插件，手写 RAG 检索与上下文构建链路（查询规划 → 候选邮件召回 → LLM 语义重排作答），另有摘要、回复草稿与截止事项提取，只写草稿、不申请发送权限。
- Agent Skill 与研究工作台：基于官方 Hermes Agent 容器搭建投资研究台，Node WebUI 服务端代理 OpenAI 兼容 API，浏览器不接触密钥；研究状态建模为分层知识图谱并记录每次修改来源（用户/AI），AI 不可覆盖用户内容、只能新增或提建议；编写图谱 Skill 契约（持久化只走后端 API），结合 Hermes 内置 Skill、记忆与历史会话，实现能力的注册、检索、编排与复用，数据落卷持久化，Given/When/Then 行为测试覆盖。
- AI 网关、可观测性与成本约束：提出共享 AI 接入层并获批 MVP 边界（网关基座＋一条本地路由＋一条批准云路由），定下数据分级、审计与 GPU 容量约束；实现 APISIX 网关与可逆隐私过滤（发出前替换敏感信息、流式返回时还原）；搭建 OpenTelemetry + Jaeger + Loki + Grafana，数据面内网直连、控制面经 WAF 隔离。
- 工程治理审查：以审查者身份诊断招聘平台延期根因——缺的是治理闭环而非开发量；建议先建黑盒回归基线再重构，并推行仓库级 AGENTS.md 与共享 AI 编码规范（支撑团队 Vibe Coding）。
- 门户重构：旧 PHP + MySQL 先容器化并补行为回归测试作基线，再迁到 React + Django/DRF（PostgreSQL、Redis/Celery、SSO、API 网关）；登录、持仓、交易、文档中心分阶段上线，并负责正式版本的持续维护；制定数据校验、切换和回滚方案。
- 数据与权限：金融持仓数据导入审批用事务、行锁、内容指纹实现幂等导入，审批绑定所见数据版本防止批准过期数据，写源文件到报表的端到端对账测试；拆分 SSO 令牌签发、MFA 与服务授权，修正账户归属校验，防止凭对象 ID

越权；文档中心双人复核发布、私有存储鉴权下载。

Klavis AI | 全栈工程师/MCP 平台架构师 2025.07 – 2026.01

- 主导 Strata 引擎，把 OpenAPI v2/v3 规范转成 Agent 可调用的 MCP 工具/Skill，并以平台服务形式对业务开放；预构建对象缓存＋引用解析优化，复杂规范加载 15 分钟 → 3 秒。
- 开发维护 20+ 第三方集成（Google Workspace、PayPal、Sentry 等），实现 OAuth 授权与令牌刷新；Playwright 会话放入独立进程并加超时清理，修复 Google Calendar 并发复用 HTTP client 的问题。
- Kubernetes/Helm 私有化部署，KEDA 按请求启动、空闲缩到零，使约 4GB 内存 VPS 按需运行数百个工具服务（成本与弹性优化）；GitHub Actions 构建、扫描、分发多架构镜像。

微软 Office 365 互操作性与合规项目 | 全栈工程师 2023.10 – 2025.07

- Python Word 兼容性测试平台（Windows API、OCR、虚拟机调度），每周自动执行 800+ 用例，人工测试时间减少约 50%；用 Copilot 与 MCP 工具 20 天内测试 400 个 Microsoft Graph API 接口。
- 国标（GB）合规文档校验工具直接修改 Word Open XML，人均校验修正时间 2.5 小时 → 5 分钟。
- 文档发布工具重构并接入 Azure Pipeline，每周处理 30GB/40 万文件，每次发布节省约 3 人天；改用 Azure Managed Identity。
- 调度任务从.NET Framework 单体迁到容器化.NET 服务，Azure 费用降低 85%、调度耗时减少 50%，流水线接入 CodeQL。

拓维信息 | Java 后端开发 2022.06 – 2023.09

- 联通 A 股门户与工单系统后端；Spring Boot 重构微服务，Kubernetes 自动部署扩缩容，实现基于 IPFS 的文件存储。

个人开源项目

Pi 下游分支与插件 | 编码 Agent，下游维护者 2026.06 – 至今

- Context Engineering：上下文压缩挪到请求发出前，保证用户输入与压缩记录的保存顺序；任务续接与结构化压缩插件；请求失败后从最后一个协议完整位置开新分支续跑，保留失败记录，未返回的工具调用标为“效果未知”。
- Agent Loop/运行时：异步工具支持后台执行、取消与取回结果，修复 Esc 后会话挂起，补伪终端与工具批次回归测试；模型目录刷新加超时并回退本地快照。
- Skill/插件生态：跨进程协作库（HMAC 握手、消息确认）、重试（配额/计费类错误不重试）、通知；Bun 打包跨平台单文件，自更新校验、备份后原子替换；补丁独立分支，CI 跟进上游。

AI-gateway | 多模型网关，独立设计与开发 2026.08 – 至今

- 入口、认证计费、模型调用用现成组件（APISIX 等），自写其间的 Go/Rust/Lua 服务：Go 模型目录、Rust 同步工具汇总上游模型与能力；APISIX Lua 按用户权限过滤模型列表（多租户隔离）并保留完整元数据。
- Go 流式代理：长推理时按 OpenAI/Anthropic 各自 SSE 格式保活，代理 WebSocket，握手失败与中途出错回传客户端；会话标识带到路由层做粘性路由，只路由不鉴权。
- 容器间与出口网络只放行必要目标；Ansible ＋固定镜像摘要部署，为权限过滤、流式错误、会话路由、网络边界写测试。

UpgradeAll | Android 应用更新管理器，项目发起人 2019.04 – 至今

- 带六人团队，聚合 GitHub、F-Droid 等更新源（1.3k+ Stars）；负责 Kotlin 客户端、Rust 更新核心与早期 Python 服务端（gRPC/REST、Redis、Docker）；2026 年完成 AGP 9/Gradle 9 迁移，Kotlin–Rust 调用统一为 WebSocket JSON-RPC，上游修复 PR#14 已合并。

教育与认证

华北理工大学 | 计算机科学与技术，本科 2023.06

红帽认证工程师 RHCE（285/300）；RHCSA（满分）；RISC-V Foundational Associate（RVFA）。ASC18 世界大学生超级计算机竞赛二等奖；入选 Linux 基金会人才激励计划。